This work is licensed under a Creative Commons license



Attribution-NonCommercial-NoDerivatives 4.0 International (CC BY-NC-ND 4.0)

You are free to:

Share copy and redistribute the material in any medium or format. Under the following terms:

Attribution You must give appropriate credit, provide a link to the license, and indicate if changes were made. You may do so in any reasonable manner, but not in any way that suggests the licensor endorses you or your use.

NonCommercial You may not use the material for commercial purposes.

NoDerivatives If you remix, transform, or build upon the material, you may not distribute the modified material.

File e processi Le system call POSIX

Giovanni Lagorio

giovanni.lagorio@unige.it
https://csec.it/people/giovanni_lagorio
Twitter & GitHub: zxgio

DIBRIS - Dipartimento di Informatica, Bioingegneria, Robotica e Ingegneria dei Sistemi University of Genova, Italy



www.zenhack.it

Outline

- Utilizzo delle system call
- 2 File (API)
- 3 Programmi binari e processi
- 4 Processi (API)
- Redirezione dell'I/O

System call

- Un processo non può interagire direttamente con l'HW
- Una chiamata di sistema = system call, AKA syscall è una "chiamata controllata" all'interno del kernel
- Per effettuare una syscall è necessario usare assembly, ma...
- La libreria C offre delle funzioni wrapper

Funzioni wrapper

Queste funzioni (chiamabili da) C,

- preparano argomenti/#-syscall secondo le convenzioni del sistema
 - Es, Linux x86: #-syscall e parametri caricati in specifici registri
- eseguono una trap (Linux x86 = INT 0x80/x64 = SYSCALL)
- il kernel
 - controlla la validità di #/argomenti
 - esegue la richiesta e scrive il risultato in un registro
 - ritorna alla modalità utente, tramite un'istruzione speciale (IRET)
- la funzione wrapper controlla il risultato
 - in caso di errore imposta errno e restituisce un codice di errore, tipicamente −1
 - altrimenti, restituisce il risultato al chiamante

Una syscall è molto più costosa di una semplice chiamata a funzione

Esito

- Controllate sempre il valore di ritorno di funzioni/syscall
- In caso di errore, errno indica la ragione del fallimento
 - potete considerarla una specie di "variabile globale" intera
 - ogni thread ha la sua
 - in caso di successo, non è detto che venga azzerata/modificata

Vedete anche errno(3), perror(3) e strerror(3)

Tipi di dato

- Varie informazioni, per esempio i PID, vengono memorizzate in int/long/...a seconda del sistema
- Scrivete codice portabile usando gli alias definiti dagli header; per esempio, getpid vi restituisce un pid_t
- Questo crea qualche problema quando si vogliono stampare con printf e funzioni simili
 - Un approccio è usate un cast a un tipo sicuramente più grande
 - Per esempio, long o long long
 - Dal C99 in poi è possibile usare intmax_t (e uintmax_t), stampandoli con %jd e %ju, definiti in stdint.h

Outline

- Utilizzo delle system call
- 2 File (API)
- 3 Programmi binari e processi
- 4 Processi (API
- 5 Redirezione dell'I/O

File descriptors

- Tutto l'I/O avviene tramite i file descriptors
 - interi non negativi che identificano un file aperto
 - "file" in senso abbastanza generale, non solo *file regolari*, anche connessioni di rete, pipe, dispositivi, . . .
 - ogni processo ha i suoi
- Tre sono "speciali" (solo per convenzione)
 - 0 STDIN_FILENO ↔ stdin/cin
 - 1 STDOUT_FILENO \leftrightarrow stdout/cout
 - 2 STDERR FILENO ↔ stderr/cerr

le costanti sono definite in unistd.h

Sul libro vedete:

http://pages.cs.wisc.edu/~remzi/OSTEP/file-intro.pdf (ma alcune cose le discuteremo più avanti, quando parleremo dell'implementazione del file-system)

System call open

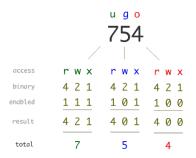
```
int open(const char *pathname, int flags[, mode_t mode]);
```

- flags bitmask che indica se si vuole aprire in lettura, scrittura, ...
 - i flag si possono recuperare e (qualcuno) modificare con fcnt1(2)
 - la maggior parte dei flag riguarda il file
 - lettura/scrittura
 - O_APPEND
 - O_NONBLOCK
 - ...

ma esistono (per ora uno: FD_CLOEXEC) flag associati al fd

- mode è utilizzato solo quando viene creato un file
 - ovvero, flags contiene O_CREAT o O_TMPFILE
 - può essere comodo specificarlo in ottale (vedere prossima slide)
 - stiamo ignorando umask(2); in pratica, mode &= ~umask
 - mode vale per le prossime aperture: possiamo tranquillamente scrivere in un file a sola lettura se abbiamo specificato O_WRONLY o O_RDWR
- viene sempre restituito il più piccolo file descriptor disponibile
 - \bullet oppure -1, in caso di errore

Permessi sui file



Presa da: https://danielmiessler.com/study/unixlinux_permissions/

Comodo: https://chmodcommand.com/

Attenzione:

- 1 ci sono altri bit, ne parleremo in seguito
- 2 per cambiare permessi/proprietario chmod/chown

chmod 777



https://twitter.com/nixcraft/status/1372473181923995651/

Battute a parte, semplificando un po', root può leggere/scrivere qualsiasi file, ed eseguire qualsiasi file purché ci sia almeno un bit x settato

Per una discussione più approfondita si veda:

https://unix.stackexchange.com/a/412247

Esercizio

Scrivete un programma che crea un file (regolare) chiamato pippo

- Che sia leggibile solo dal proprietario (non scrivibile da nessuno, proprietario compreso)
- Cosa succede se il file esiste già?
 - La syscall va a buon fine?
 - Il contenuto del file esistente viene preservato?
 - Potete fare in modo che un file già esistente non venga ri-creato per errore?
- Modificate quel file con un editor di testo (potete farlo? come?)

Ripasso (e non solo) — 1/2

- Makefile
- valgrind http://valgrind.org
 - Installazione: apt install valgrind
 - Quick-start: compilate con i simboli di debug (-ggdb), poi valgrind [--leak-check=full] eseguibile argomenti
- address sanitizer, ancora più semplice ed efficiente; compilate con:
 - -fsanitize=address -g

Ripasso (e non solo) — 2/2

- gdb (+ GEF)
 - GEF: https://gef.readthedocs.io/en/master/
 - mio "cheatsheet":
 https://github.com/zxgio/gdb_gef-cheatsheet
 - consiglio la lettura (almeno dei primi capitoli) di "GDB User manual": https://www.sourceware.org/gdb/documentation/
- Se siete "allergici" al terminale, sceglietevi un IDE (es. CLion)

Come ripasso sulla gestione della memoria dinamica, vedere: http://pages.cs.wisc.edu/~remzi/OSTEP/vm-api.pdf

System call read, write e close

- ssize_t read(int fd, void *buf, size_t count);
- ssize_t write(int fd, const void *buf, size_t count);
- int close(int fd);
 - sì, può fallire (per esempio, fd già chiuso, errori specifici di alcuni FS)
 - in ogni caso, il file descriptor viene rilasciato → ritentare la chiusura può portare a oscure race-condition in programmi multithread

Byte letti/scritti

read e write possono restituire un valore più piccolo di count (ma > 0); questo non è un errore. Per esempio, da terminale (di default) si legge solo una linea. 0 indica EOF

Esercizio

Scrivete un "cat dei poveri", ovvero un programma che

- se invocato senza parametri legge da standard-input
- altrimenti, dal/dai file specificati da riga di comando

scrivendo tutto quello che riesce a leggere su standard-output

Debugging

Per i casi più complessi serve gdb, ma spesso bastano strace o ltrace (per usare quest'ultimo, potreste dover compilare con -z lazy)

Cosa succede se specificate:

- file che non esistono?
- file che esistono ma di cui non avete il permesso di lettura?

File offset

- A ogni file aperto è associato un file offset/"pointer" che indica in che posizione leggere/scrivere (all'interno del file)
 - usato per i file regolari
 - non ha senso andare avanti/indietro su un socket, dispositivo, etc
- Dopo open l'offset è 0
- Viene spostato da read e write
- Oppure da una syscall apposta:

```
off_t lseek(int fd, off_t offset, int whence);
dove whence può essere: SEEK_SET, SEEK_CUR o SEEK_END
```

- Può essere spostato oltre la fine del file
 - questo NON cambia la dimensione del file
 - un file può avere "buchi" che corrispondono (logicamente) a byte a 0
 - ullet \rightarrow huge_file / xxd ...

Metadati di un file

Per recuperare i metadati di un file:

```
• int stat(const char *pathname, struct stat *statbuf);
  • int lstat(const char *pathname, struct stat *statbuf);

    come stat, ma non segue i link simbolici

  • int fstat(int fd, struct stat *statbuf);
struct stat {
                             // major (12 bits) + minor (20 bits)
      dev t
               st dev;
      ino_t
               st_ino;
                             // Inode number
      mode t st mode; // File type and mode
      nlink t st nlink;
                          // Number of hard links
      uid t st uid: // User ID of owner
      gid_t st_gid; // Group ID of owner
      dev_t st_rdev; // Device ID (if special file)
      off_t st_size; // Total size, in bytes
      blksize_t st_blksize; // Block size for filesystem I/O
      blkcnt_t st_blocks; // Number of 512B blocks allocated
      struct timespec st atim;
                             // Time of last access
      struct timespec st mtim; // Time of last modification
      struct timespec st_ctim; // Time of last status change
}
→ stat /tmp/huuuuuuge huge file{,.c}
```

Giovanni Lagorio (DIBRIS)

Limiti

Ogni tipo di filesystem ha dei limiti, per cui, per esempio, la lunghezza massima di un nome file può variare a seconda della directory considerata. Per leggere i limiti potete usare:

- getconf(1); per esempio: getconf NAME_MAX /bin
- fpathconf(3)/pathconf(3); per esempio: printf("%ld\n", pathconf("/bin", _PC_NAME_MAX));

Costanti POSIX: attenzione

Esistono delle costanti _POSIX_qualcosa che, nonostante abbiano "MAX" nel nome, corrispondono alla misura *minima* che deve essere garantita. Per esempio, _POSIX_NAME_MAX è 14, mentre sul mio Linux la lunghezza massima di un nome di file è 255.

Outline

- Utilizzo delle system call
- 2 File (API)
- 3 Programmi binari e processi
- 4 Processi (API)
- 5 Redirezione dell'I/O

Processo di compilazione e linking

gcc/clang sono programmi che "pilotano" l'intero processo di compilazione lanciando: preprocessore, compilatore, assemblatore e linker

Compilatori e assemblatori producono file oggetto/rilocabili:

*.c + *.h
$$\stackrel{(cpp)+cc1}{\longrightarrow}$$
 *.s $\stackrel{as}{\longrightarrow}$ *.o

• 1d, il link editor (AKA linker statico), mette assieme file-oggetto/librerie, eseguendo rilocazione e risoluzione dei simboli:

*.o (+ *.a + *.so)
$$\xrightarrow{1d}$$
 a.out

• Infine, il linking può essere...

Linking statico e dinamico

- statico
 - 1d fa tutto il lavoro, creando programmi autocontenuti
 - i "pezzi" di librerie necessari vengono copiati dentro al programma
 - gli eseguibili funzionano su "tutte" le macchine (con stesso HW/s.o.)
- (statico +) dinamico
 - 1d prepara l'eseguibile, "annotando" le dipendenze esterne
 - fra cui, il suo interprete, ovvero, il linker dinamico: ld.so
 - quest'ultimo mette assieme i pezzi mancanti a tempo di esecuzione
 - default sui sistemi moderni
 - fa risparmiare spazio, sia su disco, sia in memoria fisica
 - facilita l'aggiornamento (ma anche la "distruzione globale")
 - può essere problematico portare l'eseguibile da una macchina a un'altra

Cosa contiene un eseguibile?

Gli eseguibili, così come i file rilocabili (.o) e le librerie possono contenere:

- Codice macchina → sezione .text
- Dati e dati a sola lettura → .data e .rodata
- Metadati
 - architettura (Intel/ARM/..., 32/64 bits, little/big endian, ...)
 - entry-point; no, non è il main
 - ullet quanto spazio riservare per variabili globali non inizializzate ightarrow . bss
 - ...

In un eseguibile le sezioni vengono raggruppate in segmenti, i "pezzi" che vengono *mappati* in memoria dal s.o./linker-dinamico per l'esecuzione

Attenzione: questi segmenti NON necessariamente corrispondono ai segmenti della CPU/MMU

Spazi di indirizzamento (Address spaces)

Ogni processo "vede" il suo spazio di indirizzamento (address space), un'astrazione della memoria fisica http://pages.cs.wisc.edu/~remzi/OSTEP/vm-intro.pdf

Ovvero,

- i processi usano indirizzi logici/virtuali
- che vengono tradotti in indirizzi fisici dalla MMU http://pages.cs.wisc.edu/~remzi/OSTEP/vm-mechanism.pdf tramite:
 - segmentazione

```
\verb|http://pages.cs.wisc.edu/~remzi/OSTEP/vm-segmentation.pdf|| e/o
```

paginazione

```
http://pages.cs.wisc.edu/~remzi/OSTEP/vm-paging.pdf
http://pages.cs.wisc.edu/~remzi/OSTEP/vm-tlbs.pdf
http://pages.cs.wisc.edu/~remzi/OSTEP/vm-smalltables.pdf
```

Queste sono cose che dovreste aver visto ad "Architettura dei Calcolatori". Il succo è che: (void *)0xbadc0ff3 non è uguale per tutti ©

Cosa ci serve per far "girare" i programmi?

Ci basta mappare codice e dati, dal un ELF, per far "girare" programmi?

No, servono anche:

- stack variabili locali/temporanei, parametri, indirizzi di ritorno
 - per ragioni "storiche", cresce verso indirizzi descrescenti
- heap memoria dinamica: malloc, free, etc
 - non serve davvero un altro segmento, può crescere il segmento dati
- il kernel, non accessibile in modalità utente
- . . .

Il codice di programmi e, grazie al linking-dinamico, librerie può essere condiviso (e mappato a indirizzi *diversi*) in processi diversi

Outline

- Utilizzo delle system call
- 2 File (API)
- Programmi binari e process
- 4 Processi (API)
- Redirezione dell'I/O

(P)PID

- pid_t getpid(void)
- pid_t getppid(void)

I processi formano un albero, con radice *init* (PID=1)

• su Ubuntu in realtà è systemd, ma lo chiameremo lo stesso init ©

PID

I PID vengono riutilizzati, quindi "identificano" i processi solo in uno specifico momento

Il kernel espone le informazioni tramite lo pseudo-filesystem /proc

- una directory per ogni processo
- vari file, la maggior parte a sola lettura
 - per esempio, maps mostra lo spazio di indirizzamento
- vedere proc(5)

Directory di lavoro

Ogni processo ha una

- directory root (radice), che viene usata per tutti i percorsi assoluti (=che iniziano con /)
 - non è necessariamente la root del file-system, ne parleremo più avanti
- directory di lavoro, che viene usata per tutti i percorsi relativi; vedere
 - getcwd(2) o, estensione GNU, get_current_dir_name(3)
 restituiscono quella corrente
 - chdir(2) e fchdir(2), la modificano

API per la gestione dei processi

Le syscall principali per gestire i processi sono solo quattro:

- fork, crea un nuovo processo
- _exit (standard C: exit), termina il processo chiamante
 - quando non ci saranno ambiguità, diremo semplicemente exit
- wait, aspetta la terminazione di un processo figlio
 - non è vero al 100%, ne parliamo dopo
- execve, esegue un nuovo programma nel processo chiamante, sostituendo l'intero spazio di indirizzamento; spesso,
 - invocata dopo fork; pensate, ad esempio, alla shell
 - chiamata semplicemente *exec* o *exec**, per indicare l'intera famiglia di funzioni per eseguire programmi

Fork

pid_t fork(void)

- "clona" un processo
 - init è speciale
 - sì, in Linux esistono clone/[__]clone2/clone3, ma non ne parliamo
- creando un nuovo processo, detto "figlio" del processo chiamante
- copia quasi identica del processo chiamante
 - cambiano chiaramente PID, PPID; però
 - i FD (flag compresi) vengono duplicati
 - l'intero spazio di indirizzamento viene copiato
 - nei sistemi moderni, copia logica grazie al copy-on-write
 - in passato, "trucchi sporchi" tipo vfork per evitare la copia
- in caso di successo, ritorna due volte (!), restituendo
 - il PID del figlio al padre
 - 0 al figlio
- ightarrow fork_example1

Fork in gdb

Normalmente gdb continua a seguire solo uno dei due processi

- scegliete quale con:
 - set follow-fork-mode [child|parent]
- per seguirli entrambi (sconsigliato, è facile fare casino ②):
 set_detach-on-fork off
 - per vedere i processi collegati a gdb: info inferiors
 - per selezionare quello corrente: inferior id

Esempio: double fork

```
#include <sys/types.h>
#include <unistd.h>
int main()
₹
        // per far stare nella slide, non controllo i valori di
        // ritorno; NON fatelo nel codice "vero"
        char msg[] = "pippo\n";
        fork():
        fork();
        write(STDOUT_FILENO, msg, sizeof msg);
```

- ... quanti "pippo"?
- ightarrow double fork

Exit

```
void exit(int status) // libreria C
void _exit(int status) // syscall (in Linux, exit_group(2))
La prima:
```

- chiama le funzioni registrate con atexit(3) e on_exit(3)
- svuota i buffer di I/O
- elimina file temporanei creati con tmpfile(3)

In entrambi i casi:

- vengono chiuse/rilasciate le risorse del processo
 - file descriptor, memory-mapping, System-V IPC objects, . . .
- il processo termina con *exit-status* uguale a (status & 0xff)
 - dalla shell lo recuperate con \$?
- eventuali figli, ora orfani, vengono adottati da init (PID=1)
 - in realtà, un po' più complicato (prctl(2)), ma ignoriamo la cosa

Restituire n dal main corrisponde a exit(n); lo standard C definisce le costanti EXIT_SUCCESS (=0) ed EXIT_FAILURE (=1)

```
\rightarrow \mathtt{exit\_vs\_exit}
```

Wait

```
pid_t wait(int *wstatus)
attende un "cambio di stato" in un figlio
```

- terminazione
- stop/ripartenza, tramite segnali

per aspettare un figlio particolare e altre opzioni ightarrow waitpid(2)

Se wait va a buon fine, wstatus!=0 e

- WIFEXITED(*wstatus), allora potete recuperare lo exit-status con WEXITSTATUS(*wstatus)
- WIFSIGNALED(*wstatus), allora potete recuperare il segnale con WTERMSIG(*wstatus)
- . . .
- ightarrow fork_example2

Zombie

Un processo terminato, non aspettato dal padre, è uno zombie

- il sistema rilascia alcune risorse, ma deve continuare a memorizzare alcune informazioni, per esempio, PID ed exit-status
- quando un processo termina, viene inviato al padre il segnale SIGCHLD
 - di default è ignorato
 - può essere catturato per "aspettare" i figli
 - siccome i segnali (non realtime) non si accodano, potrebbero esserci più figli terminati per un singolo segnale

 \rightarrow gng

Exec (1/3)

Viene avviato un programma all'interno del processo chiamante, sostituendone lo spazio di indirizzamento (prox slide), ma stessi:

- PID, PPID
- file descriptor (a meno di FD_CLOEXEC)

Notate che v, 1, p ed e NON sono messe a caso ©

Exec (2/3)

Quando eseguiamo un programma il sistema (kernel+linker) prepara:

- codice, mappato r-x (.text)
- dati a sola lettura, mappati r-- (.rodata)
- dati, mappati rw- (.data, .bss e heap)
- stack, mappato rw-
 - in fondo allo stack (quindi, a indirizzi più grandi) il kernel copia:
 - le variabili d'ambiente
 - gli argomenti della riga di comando
 - (altra "roba")
- (il kernel, "invisibile")

Poi,

- in caso di linking dinamico fa la stessa cosa, ricorsivamente, per codice e dati delle librerie necessarie (+linking vero e proprio)
- quando viene creato un thread, viene anche allocato un nuovo stack

Nei sistemi moderni, codice/dati vengono portati in RAM on-demand

Exec (3/3)

Se la syscall/funzione ritorna al chiamante, qualcosa è andato storto!

Se l'eseguibile ha i bit *set-user-ID/set-group-ID* abilitato, succedono "cose" (ne parleremo in un altro momento)

$$\rightarrow$$
 exec{1,2}

Libro e API per i processi

Il libro [ADAD18] tratta le syscall per la gestione di processi nel capitolo 5: http://pages.cs.wisc.edu/~remzi/OSTEP/cpu-api.pdf

Attenzione: il libro fa un po' di confusione

A un certo punto, sembra che "creare un processo" equivalga a "voglio lanciare un programma, quindi faccio fork+exec".

- In POSIX l'unica syscall per creare un processo è fork
- Le varie exec*, a parte execve, NON sono syscall
- execve rimpiazza lo spazio di indirizzamento di un processo con quello per eseguire un programma. exec* NON creano un nuovo processo e NON fanno parte della creazione di un processo in senso stretto.

Leggete bene le pagine di manuale corrispondenti

Outline

- Utilizzo delle system call
- 2 File (API)
- Programmi binari e process
- 4 Processi (API
- 6 Redirezione dell'I/O

Dup

```
int dup(int oldfd);
```

- crea un FD equivalente a oldfd
 - a livello kernel, entrambi i FD "punteranno" allo stesso file aperto
 - potranno essere usati in modo intercambiabile: stessi offset, flag, inode
- restituisce il più piccolo FD disponibile (come open)
- non vengono copiati i flag del FD
 - FD_CLOEXEC non sarà attivo per quello nuovo; vedere fcntl(2)

```
int dup2(int oldfd, int newfd);
```

- come dup, ma usa newfd
 - chiudendolo se necessario (solo le oldfd è valido)
- se oldfd==newfd non fa nulla

Linux offre anche una dup3

Relazione fra file descriptor e file aperti: POSIX

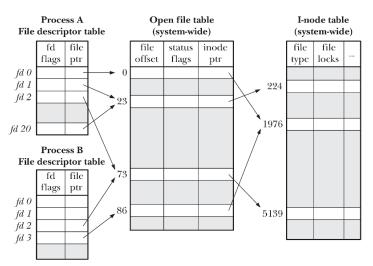


Figure 5-2: Relationship between file descriptors, open file descriptions, and i-nodes

Presa dal libro [Ker10]

Fd vs file-aperti vs inode

Notate che:

- ullet Più FD possono "puntare" lo stesso file aperto ightarrow dup(2), dup2(2)
- FD di processi diversi possono puntare lo stesso file aperto → fork(2)
 - anche FD diversi di processi diversi possono puntare lo stesso file aperto
- Più open possono aprire lo stesso file, quindi stesso inode

Quindi, è ben diverso aprire due volte lo stesso file e duplicare un FD

- anche in assenza di race conditions
- pensate a read, write e lseek

Pipe (anonime)

int pipe(int pipefd[2])

- crea un canale unidirezionale (anonimo)
- il canale è un *byte-stream*: non c'è un concetto di messaggio e/o corrispondenza fra numero di scritture e letture
- tipicamente usato per far comunicare processi
- pipefd[0] è il "lato" lettura, pipefd[1] quello scrittura
 - quello che viene scritto nella pipe finisce in un buffer del kernel
 - quando il buffer è pieno, le write vengono messe in attesa, o falliscono se flag O NONBLOCK è abilitato
 - se tutti i FD di lettura sono stati chiusi, write provoca SIGPIPE
 - quando il buffer è vuoto, le read vengono messe in attesa, o falliscono se flag O_NONBLOCK è abilitato
 - se tutti i FD di scrittura sono stati chiusi, read restituisce 0, come EOF

Vedere pipe(2) e pipe(7)

Bibliografia

[ADAD18] Remzi H. Arpaci-Dusseau and Andrea C. Arpaci-Dusseau.

Operating Systems: Three Easy Pieces.

Arpaci-Dusseau Books, August 2018.

http://pages.cs.wisc.edu/~remzi/OSTEP/.

[Ker10] Michael Kerrisk.

The Linux programming interface: a Linux and UNIX system programming handbook.

No Starch Press, 2010.